FORMULARIO DE FORMULACIÓN DE PROBLEMAS DE MACHINE LEARNING

Estrategia (Método de Google)

Nombre del proyecto	Sistema de Alerta Temprana y Prevención de Riesgo Nutricional Laboral	**Fecha**	4 de septiembre de 2026

Responsable(s)	Camila Alison Catorceno Orellana	**Área / Cliente**	Salud / Recursos Humanos

PARTE 1 ANÁLISIS ESTRATÉGICO — EL PUENTE NEGOCIO–MODELO

Enfoque Google: análisis del objetivo del cliente, de la tecnología adecuada y de las herramientas necesarias

1.1 Problema en lenguaje natural

Existen empresas cuya plantilla presenta una alta proporción de trabajadores con sobrepeso u obesidad (p. ej., trabajo de oficina, jornadas prolongadas sentado) y, en el extremo opuesto, empresas o áreas con alta proporción de personal con bajo peso (p. ej., modelaje, ballet, disciplinas de alto rendimiento estético). En ambos escenarios, cuando estas condiciones no se detectan a tiempo, el trabajador puede llegar a un estado de salud de difícil reversión (obesidad severa o desnutrición), lo que impacta su bienestar, la integridad física de la persona, el ausentismo y los costos de salud de la empresa.

Hoy la identificación suele ser tardía, ya que depende de chequeos médicos periódicos y espaciados en el tiempo, o aún peor cuando ya presenta síntomas. No existe una forma sistemática de anticipar, a partir de los hábitos alimenticios y la condición física del personal, quién está en trayectoria hacia un extremo de riesgo.

1.2 Análisis del objetivo del cliente

Resultado ideal (meta de negocio de más alto nivel):

Reducir la proporción de empleados que llegan a un estado de riesgo nutricional severo (Obesidad Tipo II/III o Peso Insuficiente) mediante la detección temprana y la derivación oportuna a los programas de salud y bienestar, antes de que la condición se vuelva difícil de revertir.

Objetivo del modelo (acción explícita y concreta a predecir):

A partir de datos demográficos, hábitos alimenticios y actividad física del empleado, clasificar su estado nutricional en una de siete categorías estandarizadas (Peso Insuficiente, Normal, Sobrepeso Nivel I/II, Obesidad Tipo I/II/III), de modo que el equipo de salud y RR. HH. puedan priorizar el seguimiento de los casos que caen en las categorías extremas o en su defecto recomendación.

1.3 Análisis de la tecnología adecuada

Filtro de formulación: ¿qué tipo de predicción resuelve el objetivo del modelo?

☐ Predecir vistas ☐ Umbrales dinámicos ☒ Umbrales fijos

Tipo de salida / técnica resultante:

☐ Regresión multidimensional ☐ Regresión ☒ Clasificación

Justificación de la elección técnica:

El objetivo del modelo es asignar una etiqueta discreta (una de 7 categorías estandarizadas de estado nutricional, definidas por umbrales fijos y conocidos de Índice de Masa Corporal) y no un valor numérico continuo; por lo tanto, no corresponde una regresión.

Al existir más de dos clases posibles (7 categorías ordenadas por severidad), el problema es de clasificación multiclase, que se abordará con Regresión Logística Softmax, un modelo lineal de clasificación multiclase.

1.4 Métricas de éxito

Negocio: (a) reducción porcentual, a 12 meses del programa, de empleados en categorías extremas (Obesidad Tipo II/III o Peso Insuficiente); (b) incremento de la tasa de derivación oportuna a nutrición / salud ocupacional; (c) reducción del ausentismo asociado a condiciones metabólicas.

Modelo: F1-score macro (para no favorecer a las clases mayoritarias en un problema con 7 clases); Recall por clase, priorizado en las categorías extremas (Obesidad Tipo II, Obesidad Tipo III, Peso Insuficiente), ya que en un sistema de alerta preventiva es preferible un falso positivo (revisar a alguien que no lo necesitaba) a un falso negativo (no detectar a alguien en riesgo); Accuracy global y matriz de confusión como apoyo diagnóstico.

1.5 Herramientas y tecnología necesarias

- Lenguaje y librerías: Python 3, pandas, NumPy, scikit-learn, matplotlib/seaborn, Jupyter Notebook.
- Fuente de datos inicial: dataset público UCI 'Estimation of Obesity Levels Based On Eating Habits and Physical Condition' para prototipar y validar el enfoque.
- Fuente de datos de producción: encuesta interna de hábitos (RR. HH. / bienestar) + datos antropométricos tomados por el servicio médico ocupacional.
- Infraestructura: almacenamiento interno con control de acceso y anonimización (dato de salud sensible), cumplimiento normativo de protección de datos personales.

PARTE 2 DISEÑO DE INGENIERÍA — EL PUENTE MODELO–SISTEMA

Enfoque Chip Huyen, adaptado con especificaciones cualitativas (no cuantitativas)

2.1 Requerimientos del sistema — cuatro pilares

Confiabilidad:

El sistema debe seguir entregando un resultado razonable (o abstenerse y derivar a revisión humana) aunque falten respuestas del cuestionario de hábitos. En ningún caso debe usarse como diagnóstico médico: es una señal de apoyo para priorizar revisiones, siempre validada por personal de salud ocupacional.

Escalabilidad:

Debe poder aplicarse periódicamente a toda la plantilla, incluso si la empresa crece o se añaden nuevas sedes, sin que el tiempo de generación de resultados se vuelva un obstáculo operativo.

Mantenibilidad:

El equipo de RR. HH./bienestar, sin ser especialista en ML, debe poder actualizar el cuestionario y solicitar el reentrenamiento del modelo al equipo de datos siguiendo un procedimiento documentado paso a paso.

Adaptabilidad:

El modelo debe poder recalibrarse si cambian los hábitos de la población (p. ej., teletrabajo, cambios en comedores corporativos) o si se incorpora una sede con una demografía distinta a la usada en el entrenamiento inicial.

2.2 Arquitectura de datos e inferencia

☐ Inferencia online (tiempo real) ☒ Inferencia batch (por lotes)

Descripción cualitativa del flujo de datos:

El empleado completa una encuesta periódica de hábitos (alimentación, actividad física, transporte) y pasa por un chequeo antropométrico del servicio médico ocupacional. Esta información se almacena de forma anonimizada, se preprocesa (codificación y escalado) y se envía al modelo, que genera un reporte agregado por categoría de riesgo para el equipo de salud ocupacional/RR. HH. El seguimiento individual de un caso puntual solo es accedido por personal médico autorizado, nunca por jefaturas directas.

2.3 Ciclo iterativo de desarrollo

Recolección de datos:

Encuesta periódica (p. ej., trimestral) de hábitos alimenticios y actividad física, más la medición antropométrica (peso, talla) tomada por el servicio médico ocupacional.

Extracción de características (featuring):

Codificación de variables binarias (sí/no) y ordinales (frecuencia de consumo entre comidas, de alcohol), codificación one-hot del medio de transporte, y escalado estándar de variables numéricas continuas (edad, talla, peso, consumo de agua, actividad física, uso de pantallas).

Entrenamiento y evaluación:

Entrenamiento de Regresión Logística Softmax con validación cruzada estratificada para explorar el hiperparámetro de regularización C, evaluando accuracy, precisión/recall/F1 macro y matriz de confusión sobre un conjunto de prueba nunca visto en el entrenamiento.

Ajuste del sistema:

Revisión periódica de las métricas por clase; si el recall de las categorías extremas cae por debajo de lo aceptable, se ajustan los pesos de clase o el umbral de decisión, y se reentrena con datos propios de la empresa a medida que se acumulen.

PARTE 3 GOBERNANZA Y AUDITORÍA

Estructura para controlar y validar el diseño — enfoque de auditoría de atributos

3.1 Validación de diseño (pre-desarrollo)

Condición (lo que el equipo propone): El modelo se usará únicamente como herramienta de apoyo y priorización, nunca como diagnóstico ni como base única para una decisión sobre el empleado.

Criterio (lo que el negocio exige): El equipo de salud ocupacional exige que el recall en las categorías extremas (Obesidad Tipo III y Peso Insuficiente) sea alto, y que toda predicción sea revisada por personal humano antes de cualquier contacto con el empleado.

Efecto / impacto si no se cumple: Riesgo de generar alarmas injustificadas o, peor, de no detectar casos reales; pérdida de confianza del personal en el programa; posible incumplimiento de normativa de protección de datos de salud y de riesgos laborales.

3.2 Identificación de causa raíz

Ante fallas o quejas en producción, se auditará primero si el error proviene de datos de entrenamiento desactualizados, de un cambio no capturado en los hábitos de la población, o de una calibración inadecuada del umbral de decisión — revisando siempre la matriz de confusión y las métricas por clase antes de decidir un reentrenamiento.

3.3 Pipeline del plan de gobernanza del modelo

1. Implementación *Despliegue al ambiente de producción*	Publicación de un reporte agregado periódico (no de fichas individuales) para el equipo de RR. HH./salud ocupacional, con acceso restringido y datos anonimizados a nivel individual sensible.
2. Comisionamiento *Pruebas de aceptación y validación inicial*	Piloto en un área o sede antes de escalar; el equipo médico valida que los perfiles señalados por el modelo sean coherentes con su criterio clínico.
3. Mantenimiento *Monitoreo, drift y degradación*	Monitoreo periódico (trimestral) de F1 macro y recall en clases extremas; alerta si cambia la composición demográfica de la plantilla (data drift).
4. Mejora continua *Reentrenamiento y nuevas iteraciones*	Reentrenamiento con datos propios de la empresa a medida que se recolecten, reemplazando gradualmente la dependencia del dataset público inicial.