INFORME TÉCNICO DEL EXPERIMENTO

Clasificación Multiclase del Nivel de Obesidad con Regresión Softmax

Proyecto Integrador — Unidad 1: Fundamentos y Modelos Lineales en Machine Learning

1. Objetivos del experimento

Objetivo general: desarrollar y evaluar un modelo de Regresión Logística Softmax capaz de clasificar el nivel de obesidad de una persona (7 categorías) a partir de sus hábitos alimenticios, actividad física y datos demográficos, como base técnica de un sistema de alerta temprana de riesgo nutricional en el contexto laboral.

Objetivos específicos:

- Formular el problema de negocio como un problema de clasificación multiclase siguiendo el enfoque Google.
- Analizar estadísticamente el dataset: estructura, calidad de datos, desbalance de clases y necesidad de escalado. y matriz de correlación?
- Entrenar un modelo de Regresión Logística Softmax exclusivamente sobre el conjunto de train, explorando el hiperparámetro de regularización C.
- Evaluar el modelo sobre un conjunto de test independiente con métricas multiclase (accuracy, precision/recall/F1) y matriz de confusión, comparando train vs. test.
- Realizar una prueba de inferencia con observaciones propias e interpretar la coherencia de las predicciones.
- Discutir los resultados, identificar limitaciones del enfoque lineal y formular conclusiones y recomendaciones.

2. Dataset

Se utilizó el dataset público "Estimation of Obesity Levels Based on Eating Habits and Physical Condition" (UCI Machine Learning Repository, DOI 10.24432/C5H31Z), con datos de personas de Colombia, Perú y México. El 23% de los registros proviene de una encuesta web real y el 77% fue generado sintéticamente con la herramienta Weka y el filtro SMOTE para balancear las clases originales.

Variable	Tipo	Descripción
Age	Numérica continua	Edad de la persona (años)
Gender	Binaria	Sexo (Male/Female)
Height	Numérica continua	Estatura (metros)
Weight	Numérica continua	Peso (kg)
family_history_with_overweight	Binaria	Antecedente familiar de sobrepeso
FAVC	Binaria	Consumo frecuente de alimentos hipercalóricos
FCVC	Numérica (1-3)	Frecuencia de consumo de vegetales
NCP	Numérica continua	Número de comidas principales al día
CAEC	Ordinal	Consumo de alimentos entre comidas (no/A veces/Frecuente/Siempre)
SMOKE	Binaria	Fuma
CH2O	Numérica continua	Consumo diario de agua (litros)
SCC	Binaria	Monitorea las calorías que consume
FAF	Numérica continua	Frecuencia de actividad física semanal
TUE	Numérica continua	Tiempo de uso de dispositivos tecnológicos
CALC	Ordinal	Frecuencia de consumo de alcohol
MTRANS	Categórica nominal	Medio de transporte habitual
NObeyesdad (target)	Categórica, 7 clases	Nivel de obesidad — variable objetivo

Variable objetivo (target) — 7 clases, ordenadas por severidad: Insufficient_Weight, Normal_Weight, Overweight_Level_I, Overweight_Level_II, Obesity_Type_I, Obesity_Type_II, Obesity_Type_III.

Relación con el objetivo de negocio: cada variable predictora corresponde a un hábito o factor modificable (alimentación, actividad física, transporte) potencialmente accionable por un programa de bienestar laboral, mientras que Height y Weight permiten ubicar a la persona en su categoría real de referencia (ver discusión sobre esta variable en la sección 7).

Licencia y consideraciones éticas: el dataset está bajo licencia CC BY 4.0 y no contiene identificadores personales. En un despliegue real con datos de una empresa, esta información debe tratarse como dato sensible de salud, anonimizada y con acceso restringido.

3. Análisis Estadístico de los Datos

3.1 Calidad de los datos

Indicador	Valor
Registros originales	2111
Valores nulos	0
Registros duplicados detectados	24
Registros tras eliminar duplicados	2087

El dataset no presenta valores nulos, pero sí 24 registros duplicados exactos (esperable dado que el 77% de los datos fue generado sintéticamente con SMOTE). Se eliminaron por no aportar información nueva y por riesgo de que, de mantenerse, el mismo registro terminará repartido entre train y test, generando una fuga de datos (data leakage) que infla artificialmente las métricas. Todas las variables categóricas/binarias fueron codificadas: variables binarias a 0/1, CAEC y CALC a escalas ordinales (0=no, 1=A veces, 2=Frecuentemente, 3=Siempre), y MTRANS mediante one-hot encoding por ser nominal sin orden natural.

3.2 Desbalance de clases

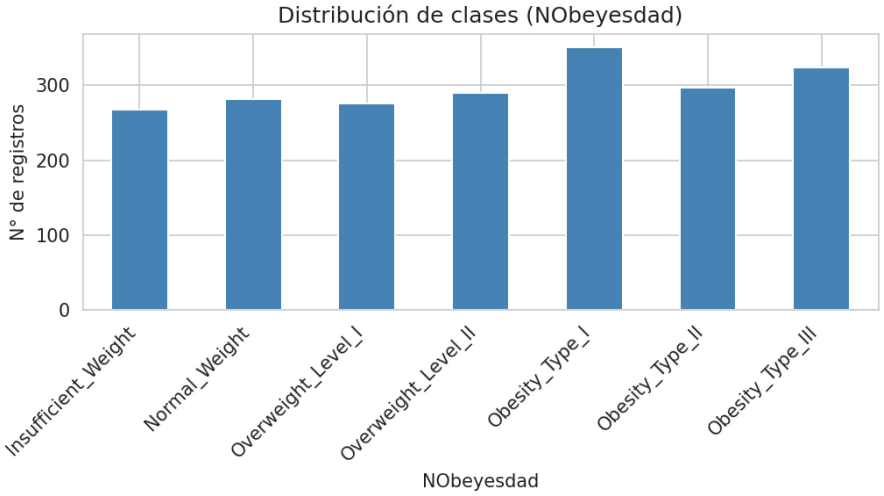


Figura 1. Distribución de registros por clase (tras eliminar duplicados).

La razón entre la clase mayoritaria y la minoritaria es de 1.31 (Obesity_Type_I con 351 registros vs. Insufficient_Weight con 267), lo que constituye un desbalance leve, no severo. Aun así, se aplicaron dos estrategias preventivas: (1) partición estratificada train/test (80/20) para preservar la proporción de clases en ambos conjuntos, y (2) el parámetro class_weight='balanced' en la Regresión Logística, que pondera el costo de cada clase de forma inversamente proporcional a su frecuencia, evitando que el modelo favorezca a las clases más numerosas al optimizar la función de costo log-loss multinomial.

3.3 Escalado de variables

Al ser la Regresión Logística Softmax un modelo lineal que combina todas las variables mediante un producto punto con los pesos ($z = \theta^T x$), las variables numéricas continuas (Age, Height, Weight, FCVC, NCP, CH2O, FAF, TUE) se estandarizaron con StandardScaler (media 0, desviación 1). El escalador se ajustó (fit) únicamente con el conjunto de entrenamiento y luego se aplicó (transform) al conjunto de test, evitando data leakage: si el escalador se ajustara con todo el dataset, el conjunto de test "filtraría" información (su media y varianza) hacia el proceso de entrenamiento.

4. Desarrollo del Experimento

4.1 Partición y exploración de hiperparámetros

Conjunto	N° de registros	% del total
Entrenamiento (train)	1669	79.97%
Prueba (test)	418	20.03%

Se exploró el hiperparámetro de regularización C (inverso de la fuerza de regularización L2) mediante validación cruzada estratificada de 5 folds sobre el train, optimizando F1-macro:

C	F1-macro promedio (CV, 5-fold)
C: 0.01	0.6035
C: 0.1	0.7625
C: 1	0.8705
C: 10	0.9286
C: 100	0.9476

El mejor valor fue C = 100, con un F1-macro de validación cruzada de 0.9476. Se observa que valores bajos de C (mayor regularización) subajustan el problema, mientras que C=100 permite al modelo lineal separar mejor las 7 clases sin señales de sobreajuste severo (ver comparación train/test en 4.2 y 5.1).

4.2 Resultados del Train

Métrica	Valor (Train)
Accuracy	0.9796
Precisión macro	0.9784
Recall macro	0.9789
F1-score macro	0.9786

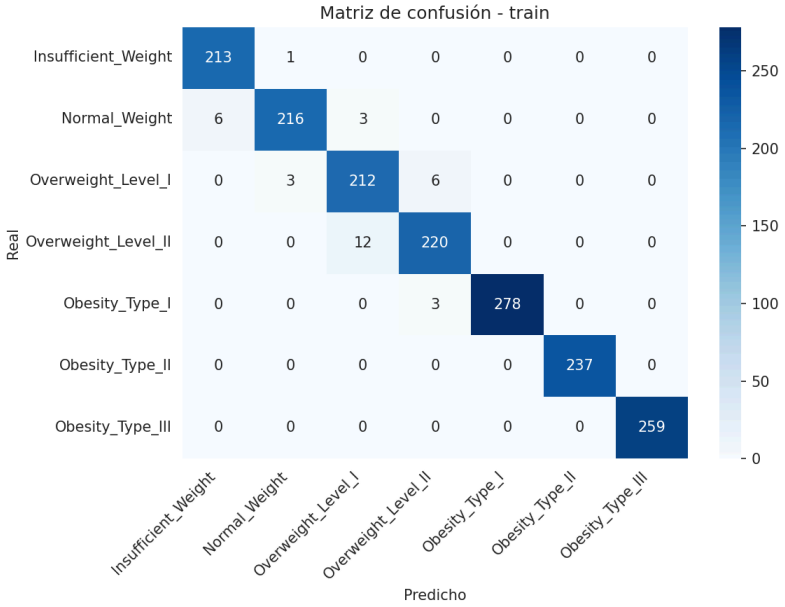


Figura 2. Matriz de confusión — conjunto de entrenamiento.

4.3 Resultados del Test

Métrica	Valor (Train)	Valor (Test)
Accuracy	0.9796	0.9593
Precisión macro	0.9784	0.9590
Recall macro	0.9789	0.9586
F1-score macro	0.9786	0.9584

Métricas por clase sobre el conjunto de test:

Clase	Precisión	Recall	F1-score	N° casos
Insufficient_Weight	0.9464	1.0000	0.9725	53
Normal_Weight	1.0000	0.9123	0.9541	57
Overweight_Level_I	0.9123	0.9455	0.9286	55
Overweight_Level_II	0.9474	0.9310	0.9391	58
Obesity_Type_I	0.9718	0.9857	0.9787	70
Obesity_Type_II	0.9508	0.9667	0.9587	60
Obesity_Type_III	0.9844	0.9692	0.9767	65

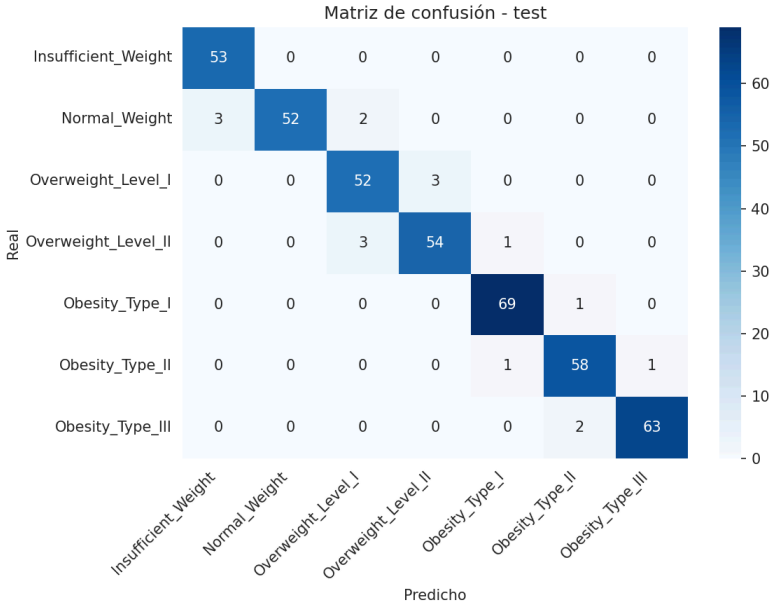


Figura 3. Matriz de confusión — conjunto de test.

4.4 Prueba con features propios

Se construyeron tres observaciones sintéticas, representativas de los perfiles descritos en el problema de negocio, y se ejecutó la predicción del modelo entrenado:

Perfil	Descripción	Predicción	Probabilidad
A	Oficinista sedentario, 34 años, alto consumo calórico, sin actividad física, se traslada en auto	Obesity_Type_I	0.9755
B	24 años, alta actividad física, dieta controlada, sin comidas entre horas, se traslada caminando	Insufficient_Weight	0.9999
C	29 años, hábitos equilibrados, actividad física moderada, transporte público	Normal_Weight	0.9992

El Perfil A (hábitos de riesgo típicos de un puesto de oficina sedentario) fue clasificado como Obesity_Type_I con alta confianza, coherente con el perfil descrito en el planteamiento del problema. El Perfil B (hábitos de restricción alimentaria y alta actividad física, similar al de una persona en una disciplina de exigencia estética) fue clasificado como Insufficient_Weight, también coherente. El Perfil C, con hábitos equilibrados, fue clasificado como Normal_Weight. Las tres predicciones son consistentes con el criterio de dominio, lo que da una validación cualitativa adicional al modelo más allá de las métricas agregadas.

5. Discusión de los Resultados

5.1 Comparación train vs. test — over/underfitting

El accuracy de train (0.9796) y de test (0.9593) son muy cercanos (brecha de 0.0203), y lo mismo ocurre con el F1-macro (0.9786 en train vs. 0.9584 en test). Según el patrón visto en clase (curvas cercanas y con error bajo en ambos conjuntos = buen ajuste), este resultado indica que el modelo generaliza correctamente y no presenta overfitting relevante ni underfitting: la regularización L2 con C=100, elegida por validación cruzada, logra un balance adecuado entre sesgo y varianza para este problema.

Es importante notar que Weight y Height son, con amplio margen, las variables con mayor peso en el modelo (ver Figura 4): esto es consistente con que las categorías de NObeyesdad están, en la práctica, definidas por rangos de Índice de Masa Corporal (IMC = Peso / Talla²). Por eso el modelo alcanza un desempeño muy alto: en gran medida está aprendiendo a reproducir el cálculo del IMC a partir de dos de sus variables de entrada, más que a predecir la

categoría únicamente a partir de hábitos de vida. Esta observación es clave para la interpretación del sistema de negocio y se retoma en la sección 5.3 y en las conclusiones.

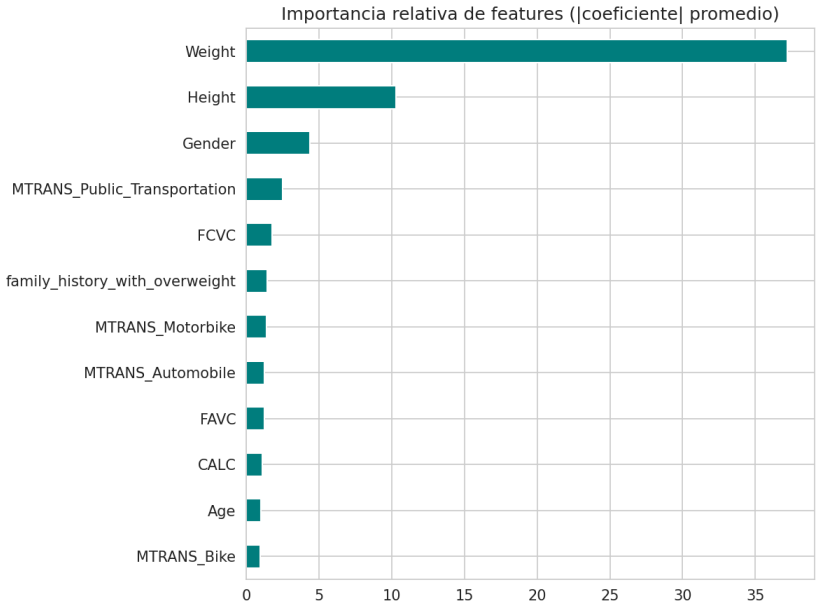


Figura 4. Importancia relativa de las variables (magnitud promedio del coeficiente Softmax por variable).

5.2 Análisis de la matriz de confusión y errores por clase

Los errores del modelo sobre el conjunto de test se concentran casi exclusivamente entre clases adyacentes en la escala de severidad (por ejemplo, Normal_Weight confundida con Overweight_Level_I, Overweight_Level_I con Overweight_Level_II, u Obesity_Type_II con Obesity_Type_III), y no se observan errores entre clases lejanas (p. ej., ningún caso de Insufficient_Weight predicho como Obesity_Type_III). Esto es consistente con la naturaleza del problema: las fronteras entre categorías de IMC son continuas y cercanas entre sí, por lo que las observaciones ubicadas justo en el límite de un umbral son las más difíciles de clasificar para un modelo lineal, mientras que los casos claramente extremos se separan con facilidad.

La clase con menor F1-score en test es Overweight_Level_I, lo cual es razonable ya que las categorías intermedias (Sobrepeso, Obesidad Tipo II) limitan por ambos lados con otra clase, mientras que las categorías extremas (Peso Insuficiente, Obesidad Tipo III) solo limitan por un lado, siendo más fáciles de separar. El desbalance leve de clases no parece ser la causa principal de estos errores, ya que la clase minoritaria (Insufficient_Weight) obtiene uno de los mejores recalls del experimento.

6. Conclusiones

- El modelo de Regresión Logística Softmax, entrenado únicamente con el conjunto de train y con regularización L2 (C=100) calibrada por validación cruzada, alcanzó un F1-score macro de 0.9584 y un accuracy de 0.9593 sobre el conjunto de test, con una brecha train-test mínima que indica buena generalización y ausencia de overfitting relevante para este dataset.
- Los errores del modelo se concentran casi exclusivamente entre categorías de severidad adyacente, nunca entre extremos opuestos de la escala, lo que confirma que el modelo captura correctamente el orden subyacente del problema aunque se entrenó como clasificación multiclase sin imponer explícitamente ese orden.
- Height y Weight dominan ampliamente la importancia de las variables, porque las clases de NObeyesdad están definidas a partir del IMC calculado con esas dos variables. En un experimento adicional (ver Anexo — Ablación) se removieron Height y Weight del conjunto de entrenamiento: el F1-macro en test cayó de 0.9584 a 0.5644 y el accuracy de 0.9593 a 0.5909. Esto demuestra que, aunque el modelo completo es muy preciso,

gran parte de su poder predictivo proviene de una relación casi determinista (el IMC) y no exclusivamente de los hábitos de vida.

- Para el caso de negocio planteado — un sistema de alerta temprana que anticipe el riesgo antes de llegar a un extremo — el hallazgo anterior es una limitación real del enfoque lineal completo: si la empresa ya cuenta con peso y talla del empleado, no necesita un modelo de Machine Learning para calcular su categoría de IMC, pues es una fórmula cerrada. El verdadero valor de un sistema predictivo estaría en el modelo reducido (solo hábitos), que aunque tiene menor desempeño (F1-macro ≈ 0.5644), sí modela una relación no trivial entre comportamiento y riesgo nutricional, útil como señal temprana de tendencia antes de que el cambio de peso ya haya ocurrido.
- Como recomendación de mejora, se propone: (a) para el reporte de monitoreo periódico, usar el modelo completo (con IMC) como clasificador de estado actual; (b) para la alerta temprana propiamente dicha, desarrollar y monitorear en paralelo el modelo reducido de solo-hábitos, evaluando si modelos no lineales (árboles, ensambles) o la incorporación de variables temporales (tendencia de hábitos en el tiempo) mejoran su capacidad predictiva sin depender del IMC ya alcanzado; y (c) en producción, complementar siempre las predicciones con revisión de personal de salud ocupacional, conforme a lo definido en la Parte 3 del formulario de formulación.

7. Anexo — Experimento de ablación (sin Height/Weight)

Para separar el efecto puramente antropométrico (IMC) del efecto de los hábitos de vida, se entrenó un segundo modelo Softmax idéntico en su configuración pero excluyendo Height y Weight del conjunto de variables. Resultados sobre el mismo conjunto de test:

Modelo	Accuracy (test)	F1-macro (test)
Completo (con Height/Weight)	0.9593	0.9584
Reducido (solo hábitos, sin Height/Weight)	0.5909	0.5644

Aun sin Height/Weight, el modelo reducido supera ampliamente el azar (1/7 ≈ 14.3% de accuracy esperado), lo que indica que los hábitos alimenticios y la actividad física sí contienen señal predictiva real sobre el riesgo nutricional, aunque su poder predictivo por sí solo sea considerablemente menor que cuando se dispone del IMC directamente.

8. Referencias

UCI Machine Learning Repository (2019). Estimation of Obesity Levels Based On Eating Habits and Physical Condition. https://doi.org/10.24432/C5H31Z